# عنوان پروژه: ساخت مدل یادگیری ماشین برای پیشبینی PIC50 روی بیماری الزایمر و تارگت cholinesterase

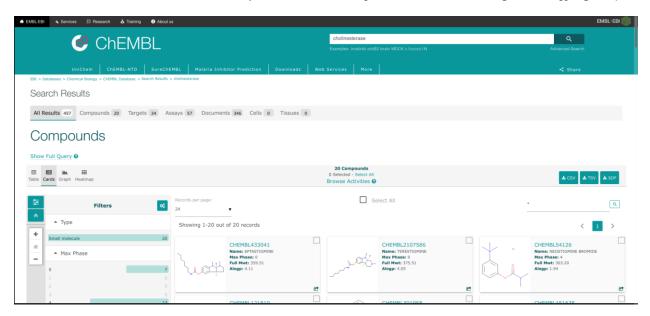
درس: طراحی محاسباتی دارو

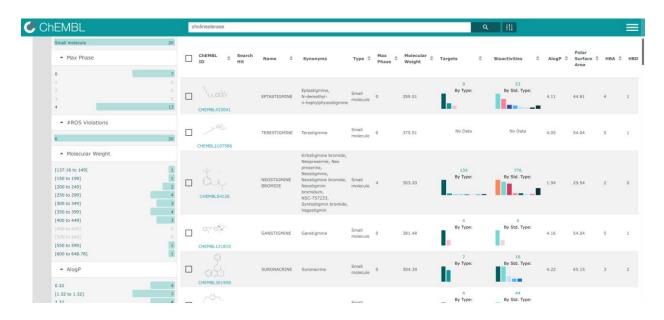
استاد: آقای دکتر قرقانی

دانشجو: محبوبه گلچین پور لیلی

- هدف: ساخت یک مدل یادگیری ماشین با استفاده از دیتای bioactivity از سایت ChEMBL برای پیشبینی PIC50 روی بیماری الزایمر و تارگت cholinesterase
  - دیتابیس مورد استفاده در پروژه: وبسایتChEMBL
  - زبان برنامه نویسی: پایتون و محیط Jupyter notebook
    - بیماری مورد نظر: آلزایمر
    - تارگت مورد نظر: cholinesterase

ابتدا تارگت پروتینی مورد نظر مان که cholinesterase است را در سایت ChEMBL از بین تارگت های موجود جست و جو می کنیم. همان طور که مشخص است ۲۰ compounde برای cholinesterase پیدا شد.



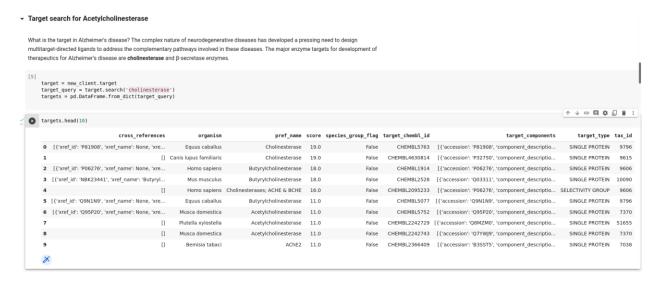


در ادامه با استفاده از محیط Jupyter notebook و زبان برنامه نویسی پایتون، جمع آوری داده ها و پیش پردازش داده ها از سابت ChEMBL انجام میشود.

ابتدا پکیج وب سرویس ChEMBL را نصب می کنیم تا دیتای bioactivity را از دیتابیس ChEMBL استخراج کنیم.

# Installing libraries Installing Installing Installing Installing Installing Installing Installing

در ادامه تارگت مورد نظر ما که در بیماری الزایمر cholinesterase انتخاب کردیم را از دیتابیس جست و جو و داده های آن را استخراج میکنیم. همانطور که مشاهد میکنید ده سطر اول داده ها قابل مشاهده می باشد.



سپس دیتای bioactivity مربوط به cholinesterase انسانی را استخراج میکنیم برای اینکار از بین داده های موجود داده سطر دوم که ارگانیسم آن با bioactivity مشخص شده است را انتخاب میکنیم و دیتای bioactivity آن را بازیابی میکنیم.

### Handling missing data

در ادامه اگر هر کامپوندی مقدارهای ستون standard\_value و یا ستون canonical\_smiles نداشته باشد آن کامپوند را حذف می کنیم.

y com	npounds has m	issing value	for the s	tandard_value and canor	nical_smiles colum	n then drop it.								
df2	= df[df.stan = df2[df.can head(4)													
	thon-input-1 2 = df2[df.c			: UserWarning: Boolean	n Series key wil	l be reindexed to m	match DataFra	mme index.						
	activity_comm	ment activ	ity_id	activity_properties	assay_chembl_id	assay_description	assay_type	assay_variant_accession	assay_variant_mutation	bao_endpoint	bao_format		target_organism	targ
0	h	lone	33968	0	CHEMBL654878	Inhibitory concentration against butyrylcholin	В	None	None	BAO_0000190	BAO_0000357	***	Homo sapiens	Butyry
1		lone	37562	п	CHEMBL654878	Inhibitory concentration against butyrylcholin	В	None	None	BAO_0000190	BAO_0000357		Homo sapiens	Butyry
2		lone	37566	п	CHEMBL654878	Inhibitory concentration against butyrylcholin	В	None	None	BAO_0000190	BAO_0000357	***	Homo sapiens	Butyry
3		lone	38901	II.	CHEMBL654878	Inhibitory concentration against butyrylcholin	В	None	None	BAO_0000190	BAO_0000357	122	Homo sapiens	Butyry

سپس سه کلاس مختلف active, inactive ,intermediate برای مقادیرستون standard\_value در نظر می گیریم و در ستون فرد دو canonical\_smiles را نیز از دیتا استخراج و در دو molecule\_chembl\_id و canonical\_smiles و canonical\_smiles و canonical\_smiles و canonical\_smiles و در دو mol\_cid و canonical\_smiles قرار میدهیم.

```
bioactivity class = []
    for i in df2.standard value:
      #print(i)
      if float(i)>= 10000:
        bioactivity class.append("inactive")
      elif float(i) <= 1000:
        bioactivity class.append("active")
      else:
        bioactivity_class.append("intermediate")
[ ] mol cid =[]
    for i in df2.molecule chembl id:
        mol_cid.append(i)
[ ] #mol_cid
    canonical_smiles =[]
    for i in df2.canonical smiles:
        canonical smiles.append(i)
   standard value =[]
    for i in df2.standard value:
        standard value.append(i)
                                                                                               + Code + 1
```

### Data pre-processing of the bioactivity data

Combine the 3 columns (molecule\_chembl\_id,canonical\_smiles,standard\_value) and bioactivity\_class into a DataFrame



در ادامه ستون های molecule\_chembl\_id, canonical\_smiles, standard\_value را در یک فایل ذخیره میکنیم.



برای مرحله دوم conda و rfkit را نصب میکنیم.

```
drive.mount('/content/drive')
      Mounted at /content/drive

    Install conda and rdkit

      ! wget https://repo.anaconda.com/miniconda/Miniconda3-py37_4.8.2-Linux-x86_64.sh
       ! chmod +x Miniconda3-py37 4.8.2-Linux-x86 64.sh
       ! bash ./Miniconda3-py37_4.8.2-Linux-x86_64.sh -b -f -p /usr/local
      ! conda install -c rdkit rdkit -y
      import sys
       sys.path.append('<u>/usr/local/lib/python3.7/site-packages/')</u>
           wheel==0.34.2=py37_0
           - xz==5.2.4=h14c3975 4
           - yaml==0.1.7=had09818_2
           - zlib==1.2.11=h7b6447c 3
      The following NEW packages will be INSTALLED:
         libacc mutex
                            pkgs/main/linux-64:: libgcc mutex-0.1-main
        asn1crypto
                            pkgs/main/linux-64::asn1crypto-1.3.0-py37 0
        ca-certificates
                            pkgs/main/linux-64::ca-certificates-2020.1.1-0
        certifi
                            pkgs/main/linux-64::certifi-2019.11.28-py37 0
        cffi
                            pkgs/main/linux-64::cffi-1.14.0-py37h2e261b9 0
        chardet
                            pkgs/main/linux-64::chardet-3.0.4-py37 1003
        conda
                            pkgs/main/linux-64::conda-4.8.2-py37_0
                            pkgs/main/linux-64::conda-package-handling-1.6.0-py37h7b6447c_0
        conda-package-han~
         cryptography
                            pkgs/main/linux-64::cryptography-2.8-py37h1ba5d50 0
         idna
                            pkgs/main/linux-64::idna-2.8-py37_0
         ld_impl_linux-64
                            pkgs/main/linux-64::ld_impl_linux-64-2.33.1-h53a641e_7
         libedit
                            pkgs/main/linux-64::libedit-3.1.20181209-hc058e9b_0
         libffi
                            pkgs/main/linux-64::libffi-3.2.1-hd88cf55_4
         libgcc-ng
                            pkgs/main/linux-64::libgcc-ng-9.1.0-hdf63c60 0
         libstdcxx-ng
                            pkgs/main/linux-64::libstdcxx-ng-9.1.0-hdf63c60_0
```

سیس دیتایی را که در مراحل قبل پیش پردازش کردیم فراخوانی میکنیم.

[1] from google.colab import drive

```
[3] import pandas as pd

of = pd.read_csv('/content/drive/MyDrive/DrugDiscovery/Data/Alzheimer/cholinesterase_0/cholinesterase_data_preprocessed.csv')
```

در این مرحله پکیج Lipinski, descriptors را نصب میکنیم. کتابخانه های آن را نصب میکنیم.

```
[5] import numpy as np
from rdkit import Chem
from rdkit.Chem import Descriptors, Lipinski
```

### ▼ Calculate descriptors

```
# Inspired by: https://codeocean.com/explore/capsules?query=tag:data-curation
     def lipinski(smiles, verbose=False):
         moldata= []
         for elem in smiles:
             mol=Chem.MolFromSmiles(elem)
             moldata.append(mol)
         baseData= np.arange(1,1)
         for mol in moldata:
             desc MolWt = Descriptors.MolWt(mol)
             desc MolLogP = Descriptors.MolLogP(mol)
             desc NumHDonors = Lipinski.NumHDonors(mol)
             desc_NumHAcceptors = Lipinski.NumHAcceptors(mol)
             row = np.array([desc_MolWt,
                             desc MolLogP,
                             desc NumHDonors,
                             desc NumHAcceptors])
             if(i==0):
                 baseData=row
                 baseData=np.vstack([baseData, row])
             i=i+1
         columnNames=["MW","LogP","NumHDonors","NumHAcceptors"]
         descriptors = pd.DataFrame(data=baseData,columns=columnNames)
         return descriptors
```

تابع Lipinski را فراخوانی و دیتا بیواکتیویتی را به عنوان ورودی به تابع می دهیم. سپس تابع مقادیر "MW","LogP","NumHDonors","NumHAcceptors" را برای ما محاسبه می کند.

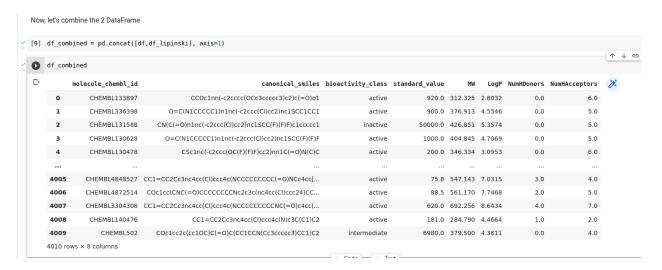
### **▼ Combine DataFrames**

Let's take a look at the 2 DataFrames that will be combined.



4010 rows × 4 columns

در ادامه مقادير محاسبه شده را به مقادير قبلي ديتافريم الحاق مي كنيم.



## در این مرحله IC50 را محاسبه و pIC50 را از روی آن بدست می آوریم.

### → Convert IC50 to pIC50

To allow IC50 data to be more uniformly distributed, we will convert IC50 to the negative logarithmic scale which is essentially -log10(IC50).

This custom function pIC50() will accept a DataFrame as input and will:

- $\bullet$  Take the IC50 values from the standard\_value column and converts it from nM to M by multiplying the value by  $10^{-9}$
- Take the molar value and apply -log10
- Delete the standard\_value column and create a new pIC50 column

```
[ ] # https://github.com/chaninlab/estrogen-receptor-alpha-qsar/blob/master/02 ER_alpha_R05.ipynb
import numpy as np

def pIC50(input):
    pIC50 = []

for i in input['standard_value_norm']:
    molar = i*(10**-9) # Converts nM to M
    pIC50.append(-np.log10(molar))

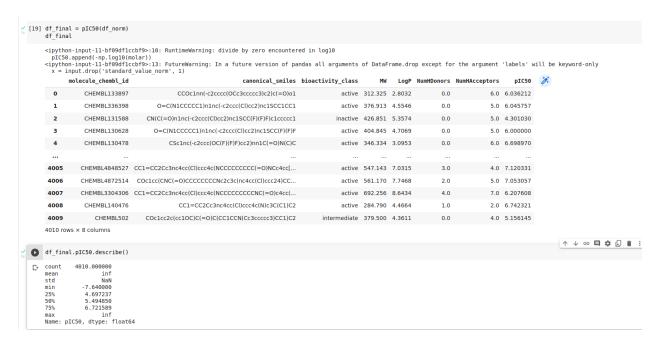
input['pIC50'] = pIC50
    x = input.drop('standard_value_norm', 1)

return x
```

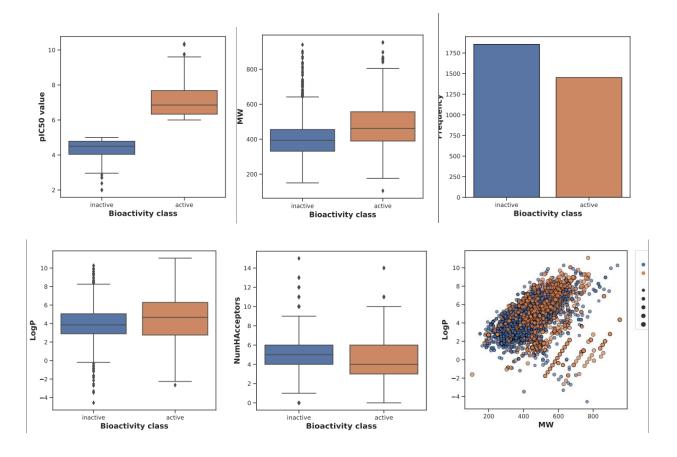
Point to note: Values greater than 100,000,000 will be fixed at 100,000,000 otherwise the negative logarithmic value will become negative.

بعد از محاسبه plC50 آن را نيز به ديتا الحاق مي كنيم و در پايان ديتا را ذخيره مي كنيم.

+ Code + Text



# در ادامه برای هر یک از مقادیر بدست آمده پلات های زیر را رسم میکنیم.



خروجی این مرحله را یکبار به صورت دیتای بیواکتیویتای که مقدار standard\_value آن نرمال شده تا سقف ۱۰۰ میلیون و با در نظر گرفتن کلاس intermediate ذخیره میکنیم.

برای مرحله سوم دیسکریپتور padel.zip را از گیت هاب دانلود و از حالت فشرده خارج میکنیم.

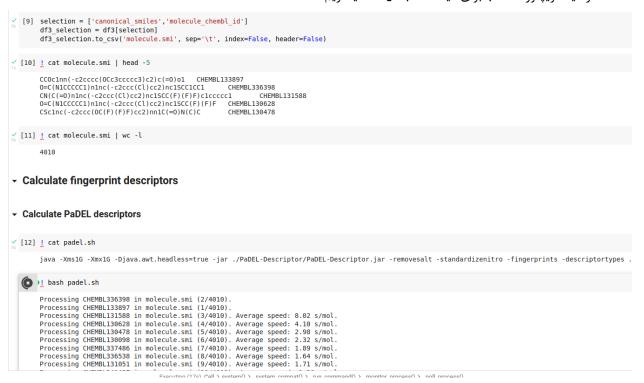
### Download PaDEL-Descriptor

```
🚺 ! wget https://github.com/dataprofessor/bioinformatics/raw/master/padel.zip
     ! wget https://github.com/dataprofessor/bioinformatics/raw/master/padel.sh
     --2023-02-06 12:04:36-- <a href="https://github.com/dataprofessor/bioinformatics/raw/master/padel.zip">https://github.com/dataprofessor/bioinformatics/raw/master/padel.zip</a>
    Resolving github.com (github.com)... 140.82.114.4
Connecting to github.com (github.com)|140.82.114.4|:443... connected.
     HTTP request sent, awaiting response... 302 Found
     Location: https://raw.githubusercontent.com/dataprofessor/bioinformatics/master/padel.zip [following]
    --2023-02-06 12:04:36-- https://raw.githubusercontent.com/dataprofessor/bioinformatics/master/padel.zip
Resolving raw.githubusercontent.com (raw.githubusercontent.com)... 185.199.108.133, 185.199.109.133, 185.199.110.133, ...
    Connecting to raw.githubusercontent.com (raw.githubusercontent.com)|185.199.108.133|:443... connected. HTTP request sent, awaiting response... 200 OK
     Length: 25768637 (25M) [application/zip]
     Saving to: 'padel.zip'
     padel.zip
                               100%[=======] 24.57M 155MB/s in 0.2s
    2023-02-06 12:04:37 (155 MB/s) - 'padel.zip' saved [25768637/25768637]
     --2023-02-06 12:04:37-- https://github.com/dataprofessor/bioinformatics/raw/master/padel.sh
     Resolving github.com (github.com)... 140.82.114.3
     Connecting to github.com (github.com)|140.82.114.3|:443... connected.
     HTTP request sent, awaiting response... 302 Found
    Location: <a href="https://raw.githubusercontent.com/dataprofessor/bioinformatics/master/padel.sh">https://raw.githubusercontent.com/dataprofessor/bioinformatics/master/padel.sh</a> [following]
    --2023-02-06 12:04:37-- <a href="https://raw.githubusercontent.com/dataprofessor/bioinformatics/master/padel.sh">https://raw.githubusercontent.com/dataprofessor/bioinformatics/master/padel.sh</a>
Resolving raw.githubusercontent.com (raw.githubusercontent.com)... 185.199.108.133, 185.199.109.133, 185.199.110.133, ...
     Connecting to raw.githubusercontent.com (raw.githubusercontent.com)|185.199.108.133|:443... connected.
     HTTP request sent, awaiting response... 200 OK
     Length: 231 [text/plain]
     Saving to: 'padel.sh'
                               100%[=========]
                                                                        231 --.-KB/s
     padel.sh
     2023-02-06 12:04:37 (11.6 MB/s) - 'padel.sh' saved [231/231]
! unzip padel.zip
```

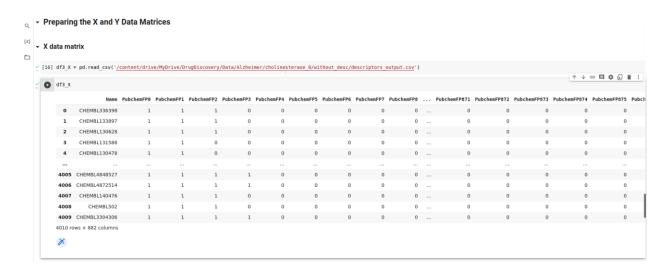
در ادامه دیتای بیواکتیویتی خروجی مرحله قبل را که بدون نرمال کردن مقدار standard\_value تا سقف ۱۰۰ میلیون و بدون کلاس intermediate ذخیره کرده بودیم را لود میکنیم.



در مرحله بعد ستون های 'canonical\_smiles','molecule\_chembl\_id' را در فایل molecule.smi ذخیره می کنیم. سپس با استفاده از دیسکریپتور padel، برای دیتا Fingerprint میسازیم.

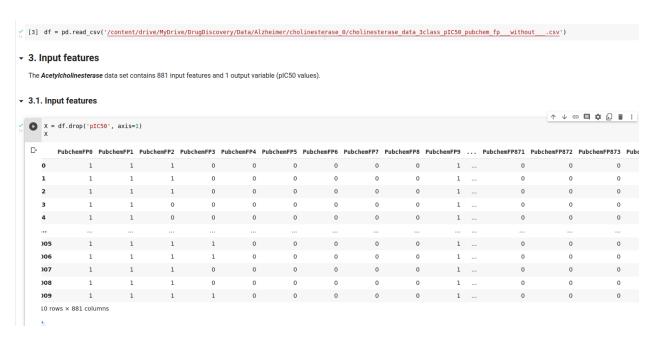


خروجی فایل دیسکریپتور شامل ۸۸۱ ستون مقدار Fingerprint به صورت زیر می باشد.



ستون pIC50 را به ستون آخر فایل دیسکریپتور الحاق کرده و فایل جدید را برای مراحل بعدی ذخیره می کنیم.

در این مرحله دیتایی که از مرحله قبل ذخیره کردیم را لود می کنیم. دیتا دارای ۸۸۱ فیچر و یک تارگت که 'pIC50' میباشد.



در این مرحله دیتا را به دو بخش train, test تقسیم میکنیم. سپس یک مدل رگرسیون با استفاده از الگوریتم Random Forest میسازیم. همانطور که مشاهده میکنید دقت r2 مدل روی داده تست 0.62 درصد می باشد.

# 

Scatter plot pic50 را برای مقدار پیش بینی شده و مقدار experimental محاسبه میکنیم.

### → 6. Scatter Plot of Experimental vs Predicted pIC50 Values

```
import seaborn as sns
    import matplotlib.pyplot as plt
    sns.set(color_codes=True)
    sns.set_style("white")
    ax = sns.regplot(Y_test, Y_pred, scatter_kws={'alpha':0.4})
    ax.set_xlabel('Experimental pIC50', fontsize='large', fontweight='bold')
    ax.set_ylabel('Predicted pIC50', fontsize='large', fontweight='bold')
    ax.set_xlim(0, 12)
    ax.set ylim(0, 12)
    ax.figure.set_size_inches(5, 5)
    plt.show
🖰 /usr/local/lib/python3.8/dist-packages/seaborn/_decorators.py:36: FutureWarning: Pass the following variables as keyword args: x,
    warnings.warn(
<function matplotlib.pyplot.show(*args, **kw)>
       10
     pIC50
     Predicted
                 Experimental pIC50
```

یک بار دیگر دیتای بیواکتیویتی خروجی مرحله قبل را که مقدار standard\_value تا سقف ۱۰۰ میلیون نرمال شده بود و کلاس r2= 0.63 آن حذف شده بود را لود میکنیم. مدل رگرسیونی را مجدد برای این دیتا میسازیم و خروجی مدل دقت co.63 ادرصد را گزارش میکند.

### ▼ 5. Building a Regression Model using Random Forest

```
+ Code + Text
       import seaborn as sns
[17] import matplotlib.pyplot as plt
       sns.set(color_codes=True)
       sns.set_style("white")
       ax = sns.regplot(Y_test, Y_pred, scatter_kws={'alpha':0.4})
       ax.set_xlabel('Experimental pIC50', fontsize='large', fontweight='bold')
       ax.set_ylabel('Predicted pIC50', fontsize='large', fontweight='bold')
       ax.set_xlim(0, 12)
       ax.set_ylim(0, 12)
       ax.figure.set_size_inches(5, 5)
       plt.show
       /usr/local/lib/python3.8/dist-packages/seaborn/_decorators.py:36: FutureWarning: Pass the following variables a
       <function matplotlib.pyplot.show(*args, **kw)>
          12
          10
        pIC50
        Predicted
           6
           2
```

	منابع
/https://www.ebi.ac.uk/chembl	
https://m.youtube.com/c/DataProfessor	
16	